

● Documento de Gobernanza Operativa — Autonomía y Seguridad del Agente

Mapa de Umbrales y Guía de Salvaguardas

Contract Sentinel — Human-in-the-Loop y Arquitectura de Seguridad

Organización: JJC

Responsable: Controlador del Futuro / Director de Project Controls

Fecha: Mayo 2026

Clasificación: Interno — Confidencial

Version: 1.0 | Revisión trimestral

TABLA DE CONTENIDOS

- 1. Proposito y Principios Rectores
- 2. El Dial de Autonomia — Marco Conceptual
- 3. Mapa de Umbrales por Tipo de Decision
 - 3.1 Presupuesto de Adicional / Deductivo
 - 3.2 Clasificacion de Variacion Contractual
 - 3.3 Alerta de Costo / EAC
 - 3.4 Alerta de Cronograma
- 4. Posicion Actual vs. Proyeccion 12 Meses
- 5. Las Cuatro Capas de Salvaguarda
 - 5.1 Restricciones Codificadas (Hard-coded)
 - 5.2 Verificacion de Output
 - 5.3 Reversibilidad por Diseno
 - 5.4 Arquitectura de Escalamiento
- 6. Comparacion: Proceso Actual vs. Contract Sentinel
- 7. Experimento de Calibracion — Shadow Mode
- 8. Gobernanza como Ventaja Competitiva

1. PROPOSITO Y PRINCIPIOS RECTORES

Este documento define los umbrales de autonomia del agente Contract Sentinel para cada tipo de decision que encontrara en produccion, y la arquitectura de salvaguardas que hace que el sistema sea seguro, auditable y reversible por diseno.

El human-in-the-loop no es un interruptor que se activa o desactiva. Es un Dial de Autonomia que el agente debe ganar bajo supervision humana.

Principio	Aplicacion en Contract Sentinel
El codigo, no el LLM, decide la permisibilidad	El Physical Key (Circuit Breaker en Python) valida cada accion propuesta contra el mapa de umbrales financieros. El modelo de lenguaje no puede sobrepasarlo bajo ninguna circunstancia.
La autonomia se gana, no se otorga	La transicion a Modo Delegado requiere DQI mayor o igual al 85% sostenido 30 dias, firma del Director de Project Controls, y cero incidentes de Falso Negativo material.
Todo output es un borrador hasta firma humana	Arquitectura de Borrador Permanente: ningun adicional, clasificacion ni alerta se convierte en accion sin confirmacion con firma digital verificada.
El agente nunca silencia una duda	Ante ambigüedad o convergencia de senales de riesgo, el agente siempre escala antes de asumir una interpretacion.

2. EL DIAL DE AUTONOMIA — MARCO CONCEPTUAL

Posicion en el Dial	Descripcion	Aplicacion en Contract Sentinel
CONSTREÑIDO	El agente solo devuelve respuestas pre-verificadas.	No aplica: el sistema tiene capacidad de razonamiento desde el inicio.
LIMITADO	Opera dentro de un espacio de decision estrecho con reglas casi determinísticas.	Clasificacion de variaciones contractuales en Dias 1-90.
SUPERVISADO	Actua, pero toda accion consecuente es revisada antes de ejecutarse.	Posicion predeterminada para todos los tipos de decision en los primeros 90 dias.
DELEGADO	Actua autonomamente dentro de umbrales; humanos revisan por excepcion.	Meta para adicionales menores a USD 5,000 y alertas de tendencia estable tras superar la Compuerta de Seguridad.
AUTONOMO	Actua y se auto-monitorea; humanos revisan solo ante anomalias flaggeadas.	No aplica en el horizonte de 12 meses para Contract Sentinel.

3. MAPA DE UMBRALES POR TIPO DE DECISION

3.1 Presupuesto de Adicional / Deductivo — Gestor de Cambios

Umbral	Condicion	Accion del Agente
AUTONOMO	Ninguno: todo borrador requiere revision mandatoria en los primeros 90 dias.	El agente genera el borrador completo (divergencia IFC, cantidad, precio unitario, clausula). Objetivo: calibrar la precision del Sub-agente IFC.
ESCALA A HUMANO	Adicionales menores a USD 5,000 con precedente confirmado: encola para revision en 48 horas. Entre USD 5,000 y USD 80,000: presenta tres escenarios y solicita decision en 5 dias habiles.	Borrador en estado PENDIENTE DE REVISION. Notificacion al Gestor de Cambios con paquete completo.
HUMANO ORIGINA	Adicionales mayores a USD 80,000, modificaciones de clausula, riesgo de disputa legal o impacto en la ruta critica.	El agente prepara el paquete de soporte. El Gestor de Cambios origina y negocia con el paquete del agente como respaldo.

3.2 Clasificacion de Variacion Contractual — Administrador de Contratos

Umbral	Condicion	Accion del Agente
AUTONOMO	Ninguno: toda clasificacion requiere confirmacion humana con score de confianza y evidencia de soporte.	Clasificacion en estado PROPUESTA. Score de confianza visible al Administrador.
ESCALA A HUMANO	Variaciones menores al 0.5% del valor del paquete, sin impacto en ruta critica y con categoria inequivoca: el agente las encola para revision mensual.	Entrada en el registro de variaciones como PENDIENTE DE REVISION MENSUAL.
HUMANO ORIGINA	Variaciones mayores al 5%, reclamacion contractual activa, penalidad activa, o patron sistematico en tres periodos consecutivos.	El agente genera analisis de patron y posicion contractual de JJC. El Administrador origina la respuesta al contratista.

3.3 Alerta de Costo / EAC — Control de Costos

Umbral	Condicion	Accion del Agente
AUTONOMO	Ninguno: todas las alertas predictivas se revisan con el controlador antes de publicarse.	Alerta en estado BORRADOR. Visible solo al Controlador del Futuro.
ESCALA A HUMANO	Variaciones de tendencia estable: el agente monitorea. Variaciones proyectadas a exceder umbral en 30 dias: genera alerta con grafico y ventana de intervencion.	Notificacion al Control de Costos con analisis de tendencia y escenarios de intervencion.
HUMANO ORIGINA	Dos o mas variaciones convergentes al umbral en menos de 15 dias, o senal de incumplimiento del contratista.	Notificacion ejecutiva inmediata al Director. El Controlador coordina la respuesta.

3.4 Alerta de Cronograma — Planificador

Umbral	Condicion	Accion del Agente
AUTONOMO	Ninguno: todas las alertas de ruta critica se revisan con el Planificador antes de publicarse.	Alerta en estado BORRADOR.
ESCALA A HUMANO	Actividades no criticas con holgura libre hasta el 30%: el agente las registra en el reporte semanal.	Entrada en reporte semanal de cronograma con indicador de holgura.
HUMANO ORIGINA	Retraso proyectado que excede el plazo contractual vigente o activa una penalidad de hito.	El agente genera analisis de impacto y opciones de compresion de cronograma. El Planificador origina el plan de recuperacion.

4. POSICION ACTUAL VS. PROYECCION 12 MESES

Tipo de Decision	Posicion Dias 1-90	Posicion 12 Meses	Condiciones de Migracion
Presupuesto Adicional/Deductivo	SUPERVISADO	DELEGADO para variaciones menores a USD 5,000 con precedente confirmado	DQI mayor o igual al 85% por 30 dias + certificacion formal del equipo de Project Controls + cero incidentes de Falso Negativo material.
Clasificacion de Variacion Contractual	LIMITADO	SUPERVISADO para variaciones menores al 0.5% del valor del paquete	DQI mayor al 85% + corpus de Memoria Institucional con 200 o mas casos validados. Variaciones mayores al 5% siempre requieren intervencion humana.
Alertas de Costo / EAC y Cronograma	SUPERVISADO	DELEGADO para tendencias estables y alertas de 30 dias	60 dias de operacion con cero Falsos Positivos materiales. Notificaciones ejecutivas de emergencia siempre requieren firma humana antes de enviarse.

"Una posicion Delegada no es una concesion al agente: es un estatus que el agente debe ganar. — McDonagh-Smith, MIT Sloan 2024"

5. LAS CUATRO CAPAS DE SALVAGUARDA

5.1 Restricciones Codificadas — Hard-coded Constraints

El Physical Key es un motor Python deterministico que valida cada accion propuesta contra la matriz de umbrales financieros. Este codigo, no el LLM, decide si una accion es permisible. Reglas absolutas codificadas:

- Ningun compromiso financiero externo se ejecuta sin firma digital verificada del Gestor de Cambios o Administrador de Contratos.
- El agente no puede modificar clausulas contractuales ni comunicarse directamente con contratistas.
- El Semaforo de Decision permanece en Rojo para todas las acciones financieras autonomas.
- Acciones que superen USD 80,000 son bloqueadas automaticamente y deben originarse desde un humano.
- Ninguna instruccion del modelo puede sobrescribir estas reglas bajo ningun contexto.

5.2 Verificacion de Output

El Agente Auditor es un sub-agente independiente que verifica que cada clausula contractual citada por la Mesa realmente exista en el PDF del contrato original, usando extraccion de texto deterministica en lugar de razonamiento probabilistico.

- El clasificador de severidad de riesgo en Python actua como segunda capa: el modelo propone, el codigo dictamina el veredicto.
- Alertas criticas reciben revision dual: un segundo modelo independiente revisa la clasificacion antes de que llegue al revisor humano.

- El modelo nunca evalúa si su propia acción es segura (NIST AI RMF, 2023).
- Chain-of-Thought garantiza que cada recomendación financiera sea trazable paso a paso (Wei et al., 2022).

5.3 Reversibilidad por Diseño

Arquitectura de Borrador Permanente: todos los outputs del agente permanecen en estado borrador con número de versión visible hasta que se reciba confirmación humana explícita vía firma digital.

- El registro de variaciones se actualiza mediante control de versiones: ninguna entrada puede sobrescribir una anterior sin dejar rastro auditable.
- Durante los primeros 90 días (Modo Sombra), el agente opera en paralelo al proceso manual sin interferir: el proceso existente permanece intacto como respaldo completo.
- Cualquier acción puede revertirse al estado anterior en un único paso por el Controlador del Futuro.

5.4 Arquitectura de Escalamiento

El agente reconoce tres condiciones que activan escalamiento automático:

Condición de Escalamiento	Acción del Agente	Destinatario
Score de confianza en interpretación de cláusula menor al 70%	Declara explícitamente su incertidumbre. No clasifica ni actúa.	Administrador de Contratos, con contexto completo del caso.
Convergencia de 2 o más señales de riesgo en menos de 15 días	Genera notificación ejecutiva directa con análisis de escenarios.	Director de Project Controls.
Solicitud que excede umbrales del Physical Key	Bloquea la acción automáticamente. Notificación inmediata.	Gestor de Cambios y Administrador de Contratos.

6. COMPARACION: PROCESO ACTUAL VS. CONTRACT SENTINEL

Dimension	Proceso Humano Actual	Contract Sentinel con Salvaguardas
Ciclo de Aprobacion	30-45 dias habiles. Cuello de botella: consolidacion manual de datos en tres fuentes independientes.	Proyectado: menos de 15 dias (-67%). El Sub-agente de Normalizacion entrega unica fuente de verdad previo a cualquier reunion. Meta Solicitud-a-Borrador: 4 horas para items estandar.
Tasa de Error	Aproximadamente 12% en reportes de costos mensuales (clasificaciones incorrectas, errores de codificacion, inconsistencias de version).	Proyectado: menos del 3% en Dia 60 (TCB mayor al 85%). Fuente residual de error: casos atipicos no presentes en Memoria Institucional.
Trazabilidad	Limitada. Decisiones dispersas en emails, actas y Excel. Reconstruir la logica de una decision de hace 60 dias puede requerir dias.	Total. Chain-of-Thought auditable: cada paso de razonamiento esta registrado junto a la clausula citada, el plano IFC de referencia, la fuente del precio unitario y el profesional que firmo.
Consistencia	Variable. Depende de la disponibilidad del analista, su experiencia y el contexto de la semana.	Alta y mejorando continuamente. El agente aplica criterios identicos codificados en la Memoria Institucional a cada caso.
Cobertura de Riesgo	Menos del 20% de variaciones activas reciben analisis sustantivo. El 80% restante se gestiona por intuicion.	100% de cobertura de variaciones activas, priorizadas por severidad. Deteccion de patrones sistemicos imposibles de identificar manualmente.
Costo por Transaccion	USD 500-1,000 (tiempo de staff, reuniones de revision, gestion documental).	Proyectado: USD 80-150 en Ano 1 (-85%). Costo residual: tiempo del Controlador del Futuro en revisiones por excepcion.

Dimension donde el agente inicialmente estara por debajo del proceso humano: la interpretacion de outliers y el contexto politico-comercial. Un controlador senior con 10 anos en un proyecto entiende intuitivamente cuando un contratista especifico tiene incentivos para inflar una reclamacion. Ese conocimiento tacito no esta aun codificado en el sistema. El Controlador del Futuro es el puente esencial entre el razonamiento analitico del sistema y las realidades politicas del proyecto.

7. EXPERIMENTO DE CALIBRACION — SHADOW MODE

El umbral mas critico a calibrar es el monto de USD 5,000 para autonomia en presupuestos de adicionales. Es una estimacion razonable, pero debe validarse contra la precision real del Sub-agente IFC en los primeros ciclos operativos.

Fase	Duracion	Actividad	Criterio de Avance
Shadow Mode	90 dias	El agente opera en paralelo al proceso manual. Cada semana, el equipo tiene una reunion de 15 minutos: que vio el agente que nosotros no vimos? El exito se mide por la calibracion de confianza entre el humano y el equipo digital.	DQI mayor o igual al 70% al final de los 90 dias para continuar. Menor al 70%: extender Shadow Mode con plan de mejora.
Compuerta de Seguridad	30 dias adicionales	Monitoreo intensivo con meta de DQI mayor o igual al 85% sostenido. Si el borrador coincide con lo que el Gestor prepararia, el umbral de autonomia sube. Si no, se identifica el patron y se ajusta el sub-agente.	DQI mayor o igual al 85% sostenido por 30 dias consecutivos.
Fase Delegada	Indefinida con revision trimestral	El agente opera autonomamente dentro de los umbrales aprobados. Revision del Dial de Autonomia cada trimestre en funcion del DQI acumulado y los cambios en condiciones del proyecto.	Mantenimiento de DQI mayor o igual al 85% y cero incidentes de Falso Negativo material.

documenta como

- Los patrones se integran durante el fine-tuning semestral del modelo.

- El Sistema de Loggi...
incertidumbre y lo con...

8. GOBERNANZA COMO VENTAJA COMPETITIVA

En JJC, la gobernanza de IA no es una carga regulatoria: es nuestro diferenciador mas poderoso en el sector minero de primera categoria en Peru, Chile y Colombia. Para los grandes operadores, la transparencia es la moneda primaria. Ya no solo compran servicios de ingenieria: compran Integridad de Proyecto Auditable.

Postura de Gobernanza	Que Significa en la Practica
AI Bill of Materials publicado	Trazabilidad completa de cada componente del sistema: version del modelo, framework de orquestacion, infraestructura, datos de entrenamiento y dependencias externas.
DQI auditado mensualmente	El indice de calidad de decision se publica internamente y se reporta al Directorio. No hay caja negra: cada numero tiene metodologia documentada.
Chain-of-Thought trazable	Cada recomendacion financiera incluye el razonamiento paso a paso, la clausula citada, el plano IFC de referencia y el precio unitario fuente. Reconstruccion instantanea de cualquier decision.
Transparencia radical sobre madurez del sistema	Durante los primeros meses, el DQI se etiqueta explicitamente como en fase de calibracion. Un cliente minero sofisticado confiara mas en un socio que publica un DQI verificado del 72% con hoja de ruta de mejora que en un competidor que afirma 99% de precision sin metodologia auditable.

"No estamos solo construyendo infraestructura: estamos construyendo la certeza de que cada dolar gastado es contractualmente solido y completamente auditable. — Hilthon Lliuyacc Leon, JJC"

Referencias

- Wei, J. et al. (2022). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. NeurIPS, 35.
- NIST. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). U.S. Dept. of Commerce.
- McDonagh-Smith, P. (2024). Module 3: Scaling Agentic AI Responsibly. MIT Sloan.
- Patlolla, K. (2024). MIT Sloan — Agentic AI for Global Industry, Modulos 2 y 3.
- Kraska, T. (2024). Module 3: Managing the Risk of Agentic Systems. MIT Sloan.